

**Avaliação final - Metodologia e Projeto para
Inteligência Artificial e Big Data II**

Helen Santana Alves da Paixão
MBA em Inteligência Artificial e Big Data

Uso de Inteligência Artificial Multimodal para Predição de Estresse Abiótico visando a Maximização de Bioativos em Cultivos Farmacêuticos Indoor

1. INTRODUÇÃO

1.1 Contextualização e Tema

O presente trabalho situa-se na fronteira tecnológica entre a Ciência da Computação e a Bioeconomia, abordando a aplicação de Inteligência Artificial (IA) e Big Data na agricultura de precisão em ambientes controlados (Indoor Farming). O foco temático desta pesquisa é a utilização de arquiteturas avançadas de Deep Learning para a análise e fusão de dados multimodais, visando a otimização de cultivos farmacêuticos de alto valor agregado. O tema emerge como resposta a um desafio crítico no cenário global: a necessidade de garantir a segurança sanitária e a soberania econômica, aumentando a produtividade e a qualidade química de matérias-primas vegetais sem o comprometimento de recursos naturais escassos.

1.2 O Problema de Pesquisa

O problema central investigado é a instabilidade na produção de fitoquímicos de alto valor agregado, um gargalo crítico para a indústria farmacêutica baseada em plantas. Em cultivos voltados à extração de princípios ativos — como a Cannabis medicinal ou espécies nativas para fitoterápicos —, a planta atua como uma biofábrica extremamente sensível. Diferentemente de processos químicos sintéticos, onde as variáveis são controladas com precisão exata, a biossíntese vegetal é amplamente influenciada pelo ambiente.

Micro-oscilações de parâmetros ambientais, como sutis variações de temperatura, umidade relativa ou concentração de dióxido de carbono (CO_2), caracterizam o que se define como estresse abiótico. Esse estresse pode inibir drasticamente a síntese de metabólitos secundários sem causar danos visuais imediatos à biomassa da planta. A ausência de métodos preditivos capazes de detectar essas anomalias fisiológicas em tempo real resulta em um fenômeno de "fenótipo silencioso": lotes visualmente saudáveis e vigorosos, mas quimicamente pobres. Essa inconsistência inviabiliza a padronização exigida por agências reguladoras (como a ANVISA) e gera prejuízos irreversíveis em toda a cadeia produtiva.

1.3 Justificativa e Motivação

A justificativa para esta pesquisa fundamenta-se em uma dupla demanda estratégica nacional: a soberania farmacêutica e a sustentabilidade hídrica. O Brasil, apesar de deter a maior biodiversidade do mundo, enfrenta uma vulnerabilidade econômica severa, importando mais de 90% dos Insumos Farmacêuticos Ativos (IFAs) utilizados pela indústria de saúde nacional, o que resulta em um déficit anual de bilhões de reais (AGÊNCIA BRASIL, 2024). A tecnologia de produção indoor assistida por IA surge como uma abordagem promissora para nacionalizar essa produção com qualidade constante, operando em sistemas que permitem uma economia hídrica de até 95% em comparação à agricultura convencional (AVGOUSTAKI; XYDIS, 2020).

Sob a ótica técnica e acadêmica, a motivação reside na oportunidade de aplicar arquiteturas de Deep Learning para a resolução de um problema de dados complexos. Diferente dos sistemas atuais que monitoram variáveis de forma isolada (apenas câmeras ou apenas termômetros), a proposta inova ao correlacionar, em tempo real, séries temporais de sensores de Internet das Coisas (IoT) com características fenotípicas extraídas via Visão Computacional. O incentivo econômico também é expressivo, visto que a bioeconomia tem o potencial de gerar um faturamento de US\$ 284 bilhões anuais no Brasil (EMBRAPA, 2023).

1.4 Objetivos

Objetivo Geral Desenvolver e validar uma arquitetura de Inteligência Artificial Multimodal baseada em Deep Learning para a predição precoce de estresse abiótico em cultivos farmacêuticos em ambientes controlados (Indoor Farming), possibilitando a emissão de alertas precoces para a maximização de bioativos e a padronização da produção.

Objetivos Específicos

1. Realizar a fusão computacional de dados heterogêneos, correlacionando séries temporais contínuas (sensores ambientais IoT) com dados discretos visuais (imagens fenotípicas).
2. Implementar e adaptar Redes Neurais Convolucionais (CNNs) para a extração automática de features fenotípicas sutis que sinalizem a perda de qualidade química.
3. Modelar a dinâmica temporal das variáveis ambientais utilizando redes profundas (como LSTMs ou Transformers) para identificar janelas críticas de estresse abiótico.

4. Desenvolver um sistema integrado de predição capaz de identificar padrões e tendências climáticas antes que ocorram danos metabólicos irreversíveis na planta.
5. Validar o modelo experimentalmente por meio de métricas de desempenho consolidadas (Acurácia, Precisão, Recall e F1-Score) e desenhar uma lógica de alertas operacionais para os produtores.

2. REFERENCIAL TEÓRICO

2.1 Estresse Abiótico e a "Biofábrica" Vegetal

6. O estresse abiótico é definido como o impacto negativo de fatores não-vivos (físico-químicos) sobre os organismos vivos em um ambiente específico. No contexto botânico, engloba extremos de temperatura, restrição hídrica, salinidade e radiação luminosa inadequada. Como as plantas são organismos sésseis, elas desenvolveram vias metabólicas complexas para aclimação (TAIZ et al., 2015).
7. A resposta ao estresse abiótico afeta diretamente a síntese de metabólitos secundários — compostos que, embora não sejam estritamente necessários para o crescimento vegetativo primário, desempenham papéis cruciais de defesa e adaptação. Na indústria farmacêutica, compostos como alcaloides, terpenos e flavonoides são os princípios ativos de interesse (VAYA; MAHMOOD, 2006). A síntese desses fitoquímicos é um processo metabolicamente custoso. Sob condições de micro-oscilações ambientais contínuas, a planta realoca sua energia para a manutenção da homeostase primária, reduzindo drasticamente a produção de metabólitos secundários. Este fenômeno resulta no "fenótipo silencioso", onde a planta mantém sua integridade macroscópica foliar, mas sofre uma degradação invisível de sua qualidade química intrínseca.

2.2 Agricultura de Precisão e Cultivos Indoor

A mitigação do estresse abiótico exige um rigoroso controle ambiental, o que levou ao desenvolvimento do Indoor Farming ou Controlled Environment Agriculture (CEA). Esses sistemas transferem a produção agrícola do campo para ambientes total ou parcialmente fechados, controlando artificialmente a iluminação (via painéis de LED ajustáveis), temperatura, umidade, concentração de CO₂ e fertirrigação.

Além de garantir rastreabilidade digital contínua e independência das sazonalidades climáticas, o cultivo indoor possui um apelo de sustentabilidade expressivo, chegando a reduzir o consumo hídrico em até 95% frente aos métodos tradicionais (AVGOUSTAKI; XYDIS, 2020). No entanto, o simples controle do ambiente não é suficiente se não houver um processamento inteligente que traduza a imensa volumetria de dados coletados (via sensores IoT) em decisões agronômicas assertivas, o que configura o papel da Agricultura de Precisão baseada em dados.

2.3 Processamento de Imagens e Séries Temporais com Deep Learning

A evolução das arquiteturas de Deep Learning revolucionou a capacidade de monitoramento agrícola. Por um lado, as Redes Neurais Convolucionais (CNNs) tornaram-se o estado da arte na Visão Computacional. Através de camadas hierárquicas de extração de características, modelos como ResNet e EfficientNet conseguem identificar padrões visuais invisíveis a olho nu, sendo amplamente utilizados para detecção de doenças e fenotipagem de plantas (HE et al., 2015).

Por outro lado, o monitoramento ambiental contínuo gera séries temporais de alta densidade. O processamento dessas variáveis sequenciais exige arquiteturas capazes de "lembrar" estados passados e entender a dependência temporal dos dados. As redes LSTM (Long Short-Term Memory) e, mais recentemente, os modelos baseados em mecanismos de atenção (como os Transformers), são excepcionalmente hábeis em mapear como o histórico de temperatura das últimas horas afeta o metabolismo atual da planta (VASWANI et al., 2017).

2.4 Inteligência Artificial Multimodal e o Estado da Arte

A vanguarda metodológica deste trabalho reside na Fusão Multimodal. O aprendizado de máquina multimodal propõe a integração inteligente de dados de origens e naturezas distintas em um espaço representativo único, partindo da premissa de que a combinação de modalidades fornece um contexto muito mais robusto do que as partes isoladas (BALTRUŠAITIS et al., 2018).

Estudos recentes têm demonstrado a eficácia da IA na agricultura, alcançando altas taxas de acurácia em bases de dados como o PlantVillage para detecção de patologias visuais (HUGHES; SALATHE, 2016). Contudo, a maioria das aplicações de IA operam em "silos": modelos visuais analisam apenas o fenótipo, enquanto modelos preditivos climáticos analisam

apenas sensores. A correlação síncrona entre o fluxo contínuo dos sensores climáticos (a causa) e a imagem foliar capturada (o efeito incipiente) para a predição da qualidade química (fitoquímicos) permanece uma lacuna na literatura científica. A arquitetura multimodal proposta neste estudo visa preencher exatamente este hiato científico, criando uma assinatura digital preventiva que sinalize a ocorrência de estresse abiótico antes que o prejuízo econômico e farmacológico se concretize.

REFERÊNCIAS BIBLIOGRÁFICAS

AGÊNCIA BRASIL. Brasil estima déficit de R\$ 20 bi com insumos farmacêuticos importados.[<https://agenciabrasil.ebc.com.br/economia/noticia/2024-08/brasil-estima-deficit-de-r-20-bi-com-insumos-farmaceuticos-importados>].

AVGOUSTAKI, D. D.; XYDIS, G. Indoor vertical farming in the urban nexus context: Business model and resource performance. *Sustainability*, v. 12, n. 5, p. 1964, 2020. DOI: <https://doi.org/10.3390/su12051964>.

BALTRUŠAITIS, T.; AHUJA, C.; MORENCY, L. P. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 41, n. 2, p. 423-443, 2018. EMBRAPA. Bioeconomia no Brasil pode gerar faturamento de US\$ 284 bi anuais.[<https://www.embrapa.br/busca-de-noticias/-/noticia/77870291/bioeconomia-no-brasil-pode-gerar-faturamento-de-us-284-bi-anuais>].

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, p. 770-778. HUGHES, D. P.; SALATHE, M. An open access repository of images on plant health to enable the development of mobile disease diagnostics. *arXiv preprint arXiv:1511.08060*, 2015. TAIZ, L.; ZEIGER, E.; MØLLER, I. M.; MURPHY, A. *Fisiologia e Desenvolvimento Vegetal*. 6. ed. Porto Alegre: Artmed, 2017. VASWANI, A.; SHAZEER, N.; PARMAR, N.; et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*, v. 30, 2017. VAYA, J.; MAHMOOD, U. Flavonoid content in leaf extracts of the fig (*Ficus carica* L.), carob (*Ceratonia siliqua* L.) and locust bean (*Ceratonia siliqua* L. var. *Silvestris*), Fenugreek (*Trigonella foenum-graecum* L.) and chicory (*Cichorium intybus* L.). *Journal of the Science of Food and Agriculture*, v. 86, n. 13, p. 2047-2052, 2006.